文字化けフローチャート

制作: 藍碌 (https://i6c.at)

CC BY NC SA 4.0 International

スタート

縺薙ｓ縺ｪ鬚ｲ縺ｵ隕九∴縺ｦ九°?

Y → UTF-8→Shift_JIS

文	字	が	縺	れ	る
e6 96 87	e5 ad 97	e3 81 8c	e7 b8 ba	e3 82 8c	e3 82 8b
諢	螫	励	'	邵	ｺ	繧	後	k

N → 英字が多い?

Y → ãåäè®æé が多い?

Y → ƒŒ—†‡€‰ が出てくる?

Y → Shift_JIS→GBK

文	字	が	縺	れ	る
95 b6 8e 9a	82 aa	e3 81	82 ea	82 e9	
曖	袈	佩	銖	傷	倦

N → ハンカクカタカナ が多い?

Y → EUC-JP→Shift_JIS

文	字	が	縺	れ	る
ca b8 bb	fa a4	ac e5 e1	a4 ec	a4 eb	
ﾊ ｸ ｻ	妤	ｬ	裔	、	･	、	･

N → ･､｡「」 が多い?

Y → UTF-8→Windows-1252

文	字	が	縺	れ	る
e6 96 87	e5 ad 97	e3 81 8c	e7 b8 ba	e3 82 8c	e3 82 8b
æ	–	‡	å	—	ã	･	Œ	ç	‚	°	ã	‚	Œ	ã	‚	‹

N → ⊥丁や 人偏の知らない漢字 が多い?

Y → Shift_JIS→GBK

N → ｽﾍﾟｰｽﾃﾞｸｷﾞﾗﾃｲﾙ?

Y → EUC-KR→Shift_JIS

글	자	가		얽	히	다
b1 db c0	da b0	a1 20	be f4	c8 f7	b4 d9
ｱ ﾛ ﾀ ﾚ	ｰ ｡		ｾ ☒		☒	ﾙ

N → GB2312/GBK→Shift_JIS

字	母	互	相	纠	缠
d7 d6 c4	b8 bb a5	cf e0	be c0	b2 f8	
ﾗ ﾖ ﾄ	ｸ ｻ ･	ﾏ	狎	ﾀ	ｲ	･

Big5-HKSCS→Shift_JIS

字	母	互	相	糾	纏
a6 72 a5	c0 a4	ac ac	db aa	c8 c4	f1
ﾗ ｒ ･	ﾀ ､	ｬ ｬ	ﾛ ｪ	ﾈ ﾄ	･

N → ÅÆ¼に加えて 多い文字は?

¤¥¡ → EUC-JP→ISO-8859-1

文	字	が	縺	れ	る
ca b8 bb	fa a4	ac e5 e1	a4 ec	a4 eb	
Ê ¸ »	ú ¤	¬ å	á ¤	ì ¤	ë

ÉÈ[→ Y → Shift_JIS→Windows-1252

文	字	が	縺	れ	る
95 b6 8e 9a	82 aa	e3 81	82 ea	82 e9	
･ ¶ Ž š	‚ ª	ã ･	ê ‚	é

N → ƒ‰— が出てくる?

N → Shift_JIS→ISO-8859-1

文	字	が	縺	れ	る
95 b6 8e 9a	82 aa	e3 81	82 ea	82 e9	
¶	š	‚ ª	ã	ê	é

N → UTF-8→ISO-8859-1

文	字	が	縺	れ	る
e6 96 87	e5 ad 97	e3 81 8c	e7 b8 ba	e3 82 8c	e3 82 8b
æ	å	ã	ç ‚ °	ã	ã

¯_(ツ)_/¯

大まかな文字コードの解説

ASCII	7ビット, 米国用 (1963年) 国際版はISO/IEC 646 ('67)
JIS X 0201	8ビット, ISO/IEC 646に片仮名などを追加 (1969年)
ISO/IEC 8859	8ビット, ASCIIの上位集合集で欧州・中亜・南亜用 (1987年)
ISO-8859-1	上の西欧用 (Latin-1) にHTTP用に制御文字を追加した ('92)
Windows-1252	2つ上の一部を文字・全角約物で置換 別名CP1252 (1991年)
JIS X 0208	日本用 漢字などを利用可能 別名区点コード (1978年)
Shift_JIS	JIS X 0201・0208を共存させる (1982年発生 1997年制定)
Windows-31J	上記のWindowsによる拡張 別名CP932, CP943 (1993年)
ISO/IEC 2022	ISO/IEC 646・8859などを併用 退避文字で符号表を切替 ('73)
ISO-2022-JP	区点コードを含むJUNETコードの規格化 ('86発生 '93制定)
EUC	ISO/IEC 2022の下位集合 東アジアでUNIXが使用
EUC-JP	EUCにシフトJISなどを適用 (1986年)
GB2312-80	2バイト, 中国版区点コード (1980年)
GBK (CP936)	2バイト, 上記+Unicode漢字のWindowsの実装 (1995年)
GB18030-2000	可変長(1, 2, 4バイト) GBK及びUnicode 3.0と互換 (2000年)
Unicode	森羅万象文字コード (1992年) 代理組で17面に拡張 ('96)
UTF-16	2バイト, Unicode の当初の表現形 追加面はサロゲートペア
UTF-8	可変長(1〜4バイト), ASCIIをそのまま扱える (1993年)